



Análise de algoritmos

K-VIZINHOS MAIS PRÓXIMOS

Baseado no livro Entendendo Algoritmos, Um guia ilustrado para programadores e outros curiosos. Aditya Y. Bhargava, Novatec, 2017.





Análise de algoritmos

K-VIZINHOS MAIS PRÓXIMOS

Pense numa situação hipotética: você necessita ir ao mercado e ao chegar, se depara com uma gôndula cheias de frutas parecidas. Para identificarmos quais são as frutas, é possível escolhermos uma fruta dentre muitas para classificar, posteriormente selecionando uma amostra considerável para comparação, chamados vizinhos próximos.

O algoritmo de k-vizinhos (KNN) mais próximos ajuda a determinar os vizinhos do objeto-base e agrupamento por similaridade, considerando características boas ou ruins de forma imparcial, idealmente. O tempo de execução do KNN no Big O é de $O(n * d)$, sendo:

- **n** sendo o número de pontos de dados no conjunto de treinamento e;
- **d** correspondente à dimensionalidade dos dados (número de atributos).

A tarefa mais importante consiste em determinar a distância entre a fruta e todas as outras frutas do conjunto de dados. Existem diversas





Análise de algoritmos

K-VIZINHOS MAIS PRÓXIMOS

abordagens para chegarmos no valor desejado, como:

- Distância Euclidiana: distância linear entre pontos, considerando o caminho mais curto;
- Distância de Manhattan: cálculo da distância de lados de um retângulo, considerando o caminho mais longo;
- Distância de *Minkowski*: generalização da distância euclidiana e de *Manhattan*;
- Distância de *Hamming*: aplicada aos dados binários, contando o número de posições que os *bits* se diferem;
- Distância do Coseno: mede a similaridade entre dois vetores, útil para dados textuais.

O teorema de Pitágoras é uma maneira simples de determinar a distância entre objetos no gráfico, considerando um conjunto de dados, seguindo o princípio da distância euclidiana. De maneira sucinta, o teorema de





Análise de algoritmos


K-VIZINHOS MAIS PRÓXIMOS

$$a^2 + b^2 = c^2$$

Pitágoras estabelece relação entre lados de um triângulo retângulo por meio da afirmação de que o quadrado da medida da hipotenusa é igual à soma dos quadrados das medidas dos catetos.

Para descobrirmos as coordenadas dos objetos no gráfico, é necessário traçarmos uma reta no eixo X e Y, determinando uma escala de valores. Interligando os pontos no gráfico, é possível determinar as coordenadas, adaptando na fórmula do Teorema de Pitágoras.

É importante mencionar que cada ponto corresponde a uma fruta, sendo seu grau de similaridade determinado pela distância.





Análise de algoritmos

K-VIZINHOS MAIS PRÓXIMOS

Foi mencionado que uma forma de separar os objetos é por meio da classificação, mas temos também a possibilidade de trabalhar com a regressão, que nada mais é do que a média de valores dos objetos para advinhar uma resposta.

APLICAÇÕES

Amplamente empregado por fazer uso de boas características para determinar a similaridade entre objetos, o algoritmo do k-vizinhos mais próximos encontra-se nos seguintes setores:

CIÊNCIA DA COMPUTAÇÃO

- Recomendação de produtos: sugestão de produtos direcionados baseado em histórico de compras e adquiridos por usuários de perfis semelhantes;
- Sistemas de filtragem: filtrar conteúdo de acordo com preferências do usuário;





Análise de algoritmos

K-VIZINHOS MAIS PRÓXIMOS

- Detecção de anomalias: identificar padrões atípicos em dados em fraudes em transações financeiras ou falhas em sistemas.

ENGENHARIA

- Controle de qualidade: classificar produtos defeituosos ou não baseados em características;
- Predição de falhas: prever falha de equipamentos industriais baseados no histórico de manutenção;
- Reconhecimento de padrões: identificar padrões em dados de sensores para otimizar processos.

BIOINFORMÁTICA

- Classificação de genes: classificação de acordo com categorias funcionais;
- Predição de estruturas de proteínas: estrutura tridimensional de uma proteína baseado em sequência de aminoácidos;





Análise de algoritmos

K-VIZINHOS MAIS PRÓXIMOS

- Expressão gênica: identificar genes em diferentes condições.

FINANÇAS

- Previsão de preços de ações: baseado em dados anteriores;
- Detecção de fraudes: transações financeiras fraudulentas;
- Análise de crédito: avaliar risco de crédito de um cliente.

MARKETING

- Segmentação de clientes: campanhas direcionadas à um grupo com interesses ou características em comum;
- Comportamento do consumidor: preferências e hábitos de consumo.

GEOCIÊNCIAS

- Classificação de solos: propriedades físicas e químicas;
- Previsão de eventos naturais: dados geofísicos para previsão.





Análise de algoritmos

K-VIZINHOS MAIS PRÓXIMOS

PROCESSAMENTO DE IMAGENS E VÍDEOS

- Reconhecimento de padrões: identificar objetos em imagens ou vídeos;
- Segmentação de imagens: dividir imagem em regiões com características semelhantes.





Análise de algoritmos

K-VIZINHOS MAIS PRÓXIMOS

A partir de agora, analisaremos um problema de K-Vizinhos Mais Próximos chamado o mínimo de espaço total desperdiçado com k operações de redimensionamento.

Você está atualmente projetando um array dinâmico. Você recebe um *array* de inteiros **indexado por 0**, $nums$, onde $nums[i]$ é o número de elementos que estarão no *array* no tempo i . Além disso, você recebe um inteiro k , o número **máximo** de vezes que você pode **redimensionar** o *array* (para qualquer tamanho).

O tamanho do *array* no tempo t , $size_t$, deve ser pelo menos $nums[t]$ porque precisa haver espaço suficiente no *array* para armazenar todos os elementos. O **espaço desperdiçado** no tempo t é definido como $size_t - nums[t]$, e o **espaço total** desperdiçado é a **soma** do espaço desperdiçado em todos os tempos t onde $0 \leq t < nums.length$.





Análise de algoritmos

K-VIZINHOS MAIS PRÓXIMOS

Retorne o mínimo de espaço total desperdiçado se você puder redimensionar o *array* no máximo k vezes.

Observação: o *array* pode ter **qualquer tamanho** no início e **não** conta para o número de operações de redimensionamento.

Exemplo 1:

Entrada: $nums = [10, 20]$, $k = 0$

Saída: 10

Explicação: $size = [20, 20]$

Podemos definir o tamanho inicial como 20.

O espaço total desperdiçado é $(20 - 10) + (20 - 20) = 10$.

Exemplo 2:

Entrada: $nums = [10, 20, 30]$, $k = 1$

Saída: 10





Análise de algoritmos

K-VIZINHOS MAIS PRÓXIMOS

Explicação: $size = [20, 20, 30]$

Podemos definir o tamanho inicial como 20 e redimensionar para 30 no tempo de 2.

O espaço total desperdiçado é $(20 - 10) + (20 - 20) + (30 - 30) = 10$.

Exemplo 3:

Entrada: $nums = [10, 20, 15, 30, 20]$, $k = 2$

Saída: 15

Explicação: $size = [10, 20, 20, 30, 30]$

Podemos definir o tamanho inicial como 10, redimensionar para 20 no tempo 1 e redimensionar para 30 no tempo 3.

O espaço total desperdiçado é $(10 - 10) + (20 - 20) + (20 - 15) + (30 - 30) + (30 - 20) = 15$.

Restrições:

- $1 \leq nums.length \leq 200$





Análise de algoritmos

K-VIZINHOS MAIS PRÓXIMOS

- $1 \leq \text{nums}[i] \leq 10^6$
- $0 \leq k \leq \text{nums.length} - 1$



/evelynthrossell





🔍 K-VIZINHOS MAIS PRÓXIMOS ✕

```
package main

import (
    "fmt"
    "math"
)

func minimumValue(a, b int) int {
    if a < b { return a }
    return b
}
```





🔍 K-VIZINHOS MAIS PRÓXIMOS ✕

```
func maximumValue(a, b int) int {  
    if a > b { return a }  
    return b  
}
```

```
const (  
    MaximumArraySize = 201  
    MaximumNumberOfResizes = 201  
)
```

```
var t [MaximumArraySize]  
[MaximumNumberOfResizes]int
```





Q K-VIZINHOS MAIS PRÓXIMOS X

```
func calculateMinimumWastedSpace(currentIndex, k
int, nums []int) int {
    n := len(nums)
    if currentIndex == n { return 0 }
    if k < 0 { return math.MaxInt32 }
    if t[currentIndex][k] != -1 {
        return t[currentIndex][k]
    }
```

```
    maximumRequiredSize := nums[currentIndex]
    totalElements := 0
    minimumWastedSpace := math.MaxInt32
```





Q K-VIZINHOS MAIS PRÓXIMOS X

```
for endIndex := currentIndex; endIndex < n;
endIndex++ {
    maximumRequiredSize =
maximumValue(maximumRequiredSize, nums[endIndex])
    totalElements += nums[endIndex]
    minimumWastedSpace =
minimumValue(minimumWastedSpace,
maximumRequiredSize * (endIndex - currentIndex + 1) -
totalElements +
calculateMinimumWastedSpace(endIndex + 1, k - 1,
nums))
```



Q K-VIZINHOS MAIS PRÓXIMOS X

```
}
t[currentIndex][k] = minimumWastedSpace
return minimumWastedSpace
}

func minimumSpaceWastedResizing(nums []int, k int) int
{
    for currentIndex := 0; currentIndex <
MaximumArraySize; currentIndex++ {
        for endIndex := 0; endIndex <
MaximumNumberOfResizes; endIndex++ {
            t[currentIndex][endIndex] = -1
        }
    }
}
```





🔍 K-VIZINHOS MAIS PRÓXIMOS ✕

```
    }  
  }  
  return calculateMinimumWastedSpace(0, k, nums)  
}  
  
func main() {  
  nums := []int{10, 20}  
  k := 0  
  result := minimumSpaceWastedResizing(nums, k)  
  fmt.Println("Minimum total space wasted to the first  
example:", result)
```





Q K-VIZINHOS MAIS PRÓXIMOS X

```
nums = []int{10, 20, 30}
k = 1
result = minimumSpaceWastedResizing(nums, k)
fmt.Println("Minimum total space wasted to the
second example:", result)
```

```
nums = []int{10, 20, 15, 30, 20}
k = 1
result = minimumSpaceWastedResizing(nums, k)
fmt.Println("Minimum total space wasted to the
third example:", result)
}
```





SAÍDA DO PROGRAMA



CENÁRIO OTIMISTA

Minimum total space wasted to the first example: 10

Minimum total space wasted to the second example: 10

Minimum total space wasted to the third example: 15





Análise de algoritmos

CONSIDERAÇÕES

Para o exemplo apresentado, seguiu-se as boas práticas de desenvolvimento com *clean code* e SOLID, na tentativa de simular um cenário otimista.

Essa iniciativa vai de encontro com a ideia de trazer conteúdos relevantes altamente abordados em processos seletivos e desmitificar a ideia de algoritmos e estrutura de dados. Espero que seja de bom proveito e bons estudos.